

Métodos de ensemble

Jhon Quiza

¿Qué son?

- Métodos que combinan clasificadores **débiles** para formar un clasificador **fuerte**.
- Clasificador débil: Aquel cuya capacidad de predicción es solo levemente superior al de una apuesta aleatoria.

$$\hat{f}_{ens}(x) = \sum_{m=1}^M \alpha_m \hat{f}_m(x)$$

Donde $\hat{f}_m(x)$ es un clasificador convencional (usualmente un árbol de decisión) que es entrenado por conjuntos diferentes de datos D_m , pero provenientes todos del mismo conjunto base $D = \{(x_i, y_i)_{i=1}^n\}$.

Tipos de métodos de ensamble

Existen 2 tipos de métodos de ensamble de acuerdo a lo que intenten reducir para disminuir el **error de generalización**:

- Los que intentan reducir varianza: Bagging y Bosques aleatorios.
- Los que intentan reducir sesgo: Boosting.

Recordemos que:

$$\mathbb{E}(y_0 - \hat{f}(x_0))^2 = \underbrace{\left[f(x_0) - \mathbb{E}(\hat{f}(x_0)) \right]^2}_{\mathbb{E}(\varepsilon^2)} + \mathbb{E} \left[\left(\hat{f}(x_0) - \mathbb{E}(\hat{f}(x_0)) \right)^2 \right] +$$

$$\mathbb{E}(y_0 - \hat{f}(x_0))^2 = \left[\text{Bias}(\hat{f}(x_0)) \right]^2 + \text{Var} \hat{f}(x_0) + \text{Var}(\varepsilon)$$

Bagging (Bootstrap aggregating)

- Los árboles de decisión son muy inestables, debido a que pequeñas variaciones de los datos pueden cambiar radicalmente las predicciones. Bagging intenta reducir esta varianza.

$$\hat{f}_{bag}(x) = \frac{1}{M} \sum_{m=1}^M \hat{f}_m(x)$$

- Bagging asume que los todos los clasificadores distribuyen de manera idéntica, esto es:

$$\begin{aligned}\mathbb{E}[\hat{f}_m(x)] &= \mu \\ \text{var} [\hat{f}_m(x)] &= \sigma^2\end{aligned}$$

Bagging (Bootstrap aggregating)

- También se asume que los clasificadores son independientes entre sí, esto es:


$$\text{cov}(\hat{f}_i(x), \hat{f}_j(x)) = \begin{cases} 0, & \text{si } i \neq j \\ \sigma^2, & \text{si } i = j \end{cases}$$

- Si las dos asunciones anteriores se cumplen se verifica que:

$$\text{var}(\hat{f}_{bag}(x)) = \text{var}\left(\frac{1}{M} \sum_{m=1}^M \hat{f}_m(x)\right) = \frac{\sigma^2(x)}{M}$$
$$\text{var}(\hat{f}_{bag}(x)) \rightarrow 0, \text{ cuando } M \rightarrow \infty$$

Bootstrap – remuestreo de datos

- ¿Cómo obtengo clasificadores diferentes, si todos son del mismo tipo? Tengo que construir bases de datos diferentes a partir de la base de datos original.
- Una forma de hacer esto es haciendo **bootstrap**, que es una técnica de selección aleatoria de datos con reemplazo.



Algoritmo bagging

1. Obtener M bases de datos a partir de la base de datos original, usando Bootstrap.
 2. Entrenar los clasificadores.
 3. Computar el clasificador bagging.
- Usualmente M está entre 50 y 100.
 - M se convierte en un parámetro que se puede optimizar utilizando cross-validation o Out-of-bag (OOB).
 - OOB toma los datos no seleccionados como conjunto de prueba para hacer validación.

Bosques aleatorios (Random forest)

- La premisa de independencia entre clasificadores no se cumple cuando todos los datos provienen de la misma parte.
- Una manera de decorrelacionar los datos es insertar algo de aleatoriedad a los clasificadores.
- El método de bosques aleatorios consigue esto seleccionando de manera aleatoria los atributos sobre los cuales cada nodo de un árbol hace una partición, esto es, de p atributos de las observaciones se seleccionan m para hacer la partición, siendo $m \leq p$.

Algoritmo de bosques aleatorios

1. Obtener B bases de datos D^{*b} a partir de la base de datos original D , usando Bootstrap.
2. Haga un árbol de decisión para cada base de datos D^{*b} , siguiendo de manera recursiva los siguientes pasos:
 - En cada nodo seleccione de manera aleatoria un subconjunto de m atributos del conjunto total de p atributos.
 - Encuentre la mejor variable dentro de los m atributos para hacer la partición.
 - Crezca el árbol hasta su máxima profundidad, sin podar, hasta alcanzar un $n_{\min}$.
3. Ensamble el bosque aleatorio con todos los clasificadores.

Algoritmo de bosques aleatorios

- Regresión:

$$\hat{f}_{rf}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}_b(x)$$

- Clasificación:

$$\hat{f}_{rf}(x) = \arg \max_{k \in y} \sum_{b=1}^B I(\hat{f}_b(x) = k)$$

- Valores típicos de m y $n_{\min}$ son:
 - Clasificación: $m = \sqrt{p}$, $n_{\min} = 1$
 - Regresión: $m = p/3$, $n_{\min} = 5$

Vamos al código...